

✓ Atividade 01 (Individual)

Não serão aceitas atividades iguais de dois alunos.

Essa será a primeira atividade valendo nota na disciplina.

Os passos para essa atividade são:

1 - Faça uma cópia de arquivo para o seu google drive, renomeie o arquivo com o seguinte nome: "Atividade 01 - Seu Nome.ipynb", em que "Seu Nome" deve substituído pelo seu nome.

2 - Abra o arquivo no Colab.

3 - Rode todos os códigos abaixo no Colab.

4 - Responda todas as perguntas abaixo que são numeradas de 1 até 7.

5 - Imprima em PDF esse documento e entregue a atividade no Classroom.

Fonte da base de dados: <https://archive.ics.uci.edu/dataset/162/forest+fires>

Serão apresentadas análise de dados sobre incêndios florestais no noroeste de Portugal.

Tabela de features em inglês (Não deu tempo de traduzir)

Variable Name	Role	Type	Description	U
X	Feature	Integer	x-axis spatial coordinate within the Montesinho park map: 1 to 9	
Y	Feature	Integer	y-axis spatial coordinate within the Montesinho park map: 2 to 9	
month	Feature	Categorical	month of the year: 'jan' to 'dec'	
day	Feature	Categorical	day of the week: 'mon' to 'sun'	
FFMC	Feature	Continuous	FFMC index from the FWI system: 18.7 to 96.20	
DMC	Feature	Integer	DMC index from the FWI system: 1.1 to 291.3	
DC	Feature	Continuous	DC index from the FWI system: 7.9 to 860.6	
ISI	Feature	Continuous	ISI index from the FWI system: 0.0 to 56.10	
temp	Feature	Continuous	temperature: 2.2 to 33.30	Celsius
RH	Feature	Integer	relative humidity: 15.0 to 100	

✓ Importando as bibliotecas e importando a base de dados

```
import pandas as pd
```

```
import matplotlib.pyplot as plt
```

```
ff = pd.read_csv('https://raw.githubusercontent.com/OrlandoIFPR/ml2/main/Dat
```

```
ff.head()
```

	X	Y	month	day	FFMC	DMC	DC	ISI	temp	RH	wind	rain	area
0	7	5	mar	fri	86.2	26.2	94.3	5.1	8.2	51	6.7	0.0	0.0
1	7	4	oct	tue	90.6	35.4	669.1	6.7	18.0	33	0.9	0.0	0.0
2	7	4	oct	sat	90.6	43.7	686.9	6.7	14.6	33	1.3	0.0	0.0
3	8	6	mar	fri	91.7	33.3	77.5	9.0	8.3	97	4.0	0.2	0.0
4	8	6	mar	sun	89.3	51.3	102.2	9.6	11.4	99	1.8	0.0	0.0

1 - O que o método `head()` faz e para o que serve?

Serve para retornar em ordem as linhas do dataset, pode ser usado um valor como parametro, retornando o n numero de colunas parametrizado

✓ Removendo as Colunas que não serão usadas na análise

```
ff = ff.drop(columns=['FFMC', 'DMC', 'DC', 'ISI'])  
ff.head()
```

	X	Y	month	day	temp	RH	wind	rain	area
0	7	5	mar	fri	8.2	51	6.7	0.0	0.0
1	7	4	oct	tue	18.0	33	0.9	0.0	0.0
2	7	4	oct	sat	14.6	33	1.3	0.0	0.0
3	8	6	mar	fri	8.3	97	4.0	0.2	0.0
4	8	6	mar	sun	11.4	99	1.8	0.0	0.0

✓ Gerando estatísticas sobre todos os dados numéricos

```
ff.describe()
```

	X	Y	temp	RH	wind	rain
count	517.000000	517.000000	517.000000	517.000000	517.000000	517.000000
mean	4.669246	4.299807	18.889168	44.288201	4.017602	0.021663
std	2.313778	1.229900	5.806625	16.317469	1.791653	0.295959
min	1.000000	2.000000	2.200000	15.000000	0.400000	0.000000
25%	3.000000	4.000000	15.500000	33.000000	2.700000	0.000000
50%	4.000000	4.000000	19.300000	42.000000	4.000000	0.000000
75%	7.000000	5.000000	22.800000	53.000000	4.900000	0.000000
max	9.000000	9.000000	33.300000	100.000000	9.400000	6.400000

2 - O método `describe()` gera várias estáticas sobre os dados. Explique os seguintes resultados e para o que servem:

1. `count`
2. `mean`
3. `std`
4. `min`
5. `25%`
6. `50%`
7. `75%`
8. `max`


-
1. `count` conta quantos valores válidos (não nulos) existem na coluna. Aqui deu 517 em todas, ou seja, nenhum registro faltando.
 2. `mean` é a média aritmética da coluna, soma tudo e divide pela quantidade. Serve para saber o valor típico, por exemplo a temperatura média de 18,88 °C.
 3. `std` é o desvio padrão, mostra o quanto os valores se afastam da média. Quanto maior, mais espalhados estão os dados. Na coluna `area` o std de 63,65 é muito maior que a média de 12,84, o que indica dados bem dispersos e com valores extremos.
 4. `min` é o menor valor da coluna. Serve para ver o limite inferior dos dados, por exemplo a temperatura mínima de 2,2 °C.
 5. `25%` é primeiro quartil, o valor que separa os 25% menores dados. Aqui mostra que pelo menos 25% dos registros tiveram área queimada igual a 0.
 6. `50%` é segundo quartil, também chamado de mediana, é o valor do meio quando os dados estão ordenados. Serve como medida de centro que não é

afetada por valores extremos, por isso a mediana da área é 0,52 enquanto a média é 12,84.

7. `75%` é terceiro quartil, o valor que separa os 75% menores dados. Aqui mostra que 75% dos incêndios queimaram até 6,57 ha.
8. `max` é o maior valor da coluna. Serve para ver o limite superior e identificar outliers, como a área máxima de 1090,84 ha.

✓ Gerando um gráfico de ocorrências por mês

```
por_mes = ff['month'].value_counts().sort_values(ascending=[True])
por_mes.plot(kind='barh', label="Quantidade de Incêndio por mês", figsize=(8
plt.xticks(rotation=120);
```



3 - Explique os seguintes métodos:

- `value_counts()`
- `sort_values()`
- `plot()`

O `value_counts()` conta quantas vezes cada valor diferente aparece na coluna, retornando uma Series com o valor como índice e a quantidade como conteúdo. Na coluna `month` ele mostrou que ago teve 184 ocorrências e set 172, sendo os meses com mais incêndios.

O `sort_values()` ordena os dados pelos valores. Com `ascending=True` ordena do menor para o maior e com `ascending=False` do maior para o menor. Aqui foi usado para deixar as barras do gráfico em ordem crescente de quantidade.

Já o `plot()` gera o gráfico a partir do DataFrame ou da Series usando o matplotlib. O parâmetro `kind` define o tipo do gráfico (barh, bar, line, pie, etc) e os outros parâmetros configuram tamanho (`figsize`), grade (`grid`), cor (`color`) e legenda (`legend`).

4 - Responda as seguintes perguntas:

1. O grafico de barras horizontais é adequado para esse tipo de dados? Justifique a resposta.
2. Quais melhorias você faria nesse gráfico? Justifique porque.


1. Sim, é adequado. O mês é uma variável categórica e o que está sendo mostrado é a contagem de ocorrências de cada categoria, que é justamente o que um gráfico de barras representa bem. A versão horizontal ainda ajuda porque são 12 categorias e os nomes dos meses ficam escritos na horizontal, sem precisar girar o texto, o que facilita a leitura e a comparação entre os meses.

2.

- Tirar o `plt.xticks(rotation=120)`. Girar os números do eixo x em 120 graus deixa os valores de cabeça para baixo e só atrapalha a leitura.
- Colocar título no gráfico e nome nos eixos ("Quantidade de incêndios" no x e "Mês" no y), porque hoje só existe a legenda e o leitor precisa deduzir o que cada eixo representa.
- Trocar a cor `lime` por uma cor mais frote, porque o verde limão tem pouco contraste com o fundo branco e cansa a vista.
- Ordem cronológica dos meses (jan a dez).
- Escrever o valor da contagem na ponta de cada barra, assim dá para saber o número exato sem precisar estimar pela grade.
- Traduzir as siglas dos meses para o português, já que o resto da análise está em português.

Gerando um gráfico com os dados da umidade relativa média por mês

```
por_umidade = ff[['month', 'RH']].groupby('month').mean()
por_umidade.plot(kind='bar', figsize=(10, 5));
```



5 - Explique os seguintes métodos:

- `groupby()`
- `mean()`

`groupby()` Agrupa as linhas do DataFrame pelos valores de uma ou mais colunas, juntando num mesmo grupo todas as linhas que têm o mesmo valor. Sozinho ele apenas cria os grupos, é preciso uma função de agregação depois para gerar o resultado. Aqui ele agrupou todas as linhas pelo mês.

`mean()` Calcula a média aritmética dos valores. Aplicado depois do `groupby('month')`, ele calcula a média da umidade relativa dentro de cada mês separadamente, retornando um valor por mês em vez de um único valor do dataset inteiro.

6 - Responda as seguintes perguntas:

1. O grafico de barras verticais é adequado para esse tipo de dados? Justifique a resposta.
2. Quais melhorias você faria nesse gráfico? Justifique porque.

1. É adequado em parte. Como se trata de comparar um valor numérico (a média de RH) entre categorias (os meses), o gráfico de barras cumpre bem esse papel. Porém os meses formam uma sequência temporal, então um gráfico de linhas mostraria melhor a variação da umidade ao longo do ano. Além disso a média esconde a quantidade de registros de cada mês, por exemplo, jan tem apenas 2 registros e nov apenas 1, e mesmo assim aparecem com o mesmo peso visual de ago, que tem 184 registros, o que passa uma impressão errada de confiabilidade.

2.

- Ordenar os meses na ordem do calendário, porque o `groupby()` ordena em ordem alfabética (abr, ago, dez, fev...) e isso quebra a leitura da sazonalidade.
- Colocar título e nome nos eixos, deixando claro que o eixo y é a umidade relativa média em porcentagem.
- Indicar a quantidade de registros de cada mês (no rótulo ou com barra de erro/desvio padrão), para deixar explícito que as médias de jan, mai e nov vêm de pouquíssimas amostras.
- Deixar os nomes dos meses na horizontal, já que são siglas curtas e não precisam ficar inclinadas.
- Considerar trocar por um gráfico de linha, que representa melhor a evolução da umidade ao longo do ano.

7 - Sugira mais dois gráficos de análises que poderiam ser feitas para esses dados. Não precisa colocar os gráficos, somente fazer as sugestões de análises a serem feitas.

Uma seria um gráfico de dispersão da temperatura contra a área queimada, com a temperatura no eixo x e a área no eixo y. A análise seria verificar se existe relação entre dias mais quentes e incêndios maiores. Como a coluna `area` tem muitos zeros e alguns valores extremos, daria para aplicar log na área ou filtrar somente os registros com área maior que zero para enxergar melhor a relação. A mesma ideia serve para a umidade relativa (RH) contra a área, onde a expectativa é de uma relação inversa.

A outra sugestão, seria um mapa de calor das coordenadas X e Y do parque, que contaria quantos incêndios ocorreram em cada posição da grade. A análise seria identificar quais regiões do parque Montesinho concentram mais ocorrências, o que ajudaria a direcionar a prevenção e a fiscalização para essas áreas. Uma variação seria somar a área queimada em vez de contar as ocorrências, para ver onde os incêndios foram mais destrutivos.

