

	species	island	bill_length_mm	bill_depth_mm	flipper_length_mm	body_
0	Adelie	Torgersen	39.1	18.7		181.0
1	Adelie	Torgersen	39.5	17.4		186.0
2	Adelie	Torgersen	40.3	18.0		195.0
4	Adelie	Torgersen	36.7	19.3		193.0
5	Adelie	Torgersen	39.3	20.6		190.0

Próximas etapas:

[Gerar código com df](#)

[New interactive sheet](#)

```
df.info()
df.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 333 entries, 0 to 343
Data columns (total 7 columns):
#   Column                Non-Null Count  Dtype
---  -
0   species               333 non-null   object
1   island                333 non-null   object
2   bill_length_mm        333 non-null   float64
3   bill_depth_mm         333 non-null   float64
4   flipper_length_mm     333 non-null   float64
5   body_mass_g           333 non-null   float64
6   sex                   333 non-null   object
dtypes: float64(4), object(3)
memory usage: 20.8+ KB
```


	bill_length_mm	bill_depth_mm	flipper_length_mm	body_mass_g	
count	333.000000	333.000000	333.000000	333.000000	
mean	43.992793	17.164865	200.966967	4207.057057	
std	5.468668	1.969235	14.015765	805.215802	
min	32.100000	13.100000	172.000000	2700.000000	
25%	39.500000	15.600000	190.000000	3550.000000	
50%	44.500000	17.300000	197.000000	4050.000000	
75%	48.600000	18.700000	213.000000	4775.000000	
max	59.600000	21.500000	231.000000	6300.000000	



✓ Grafico 1 - Histograma da massa corporal por especie

```
plt.figure(figsize=(8, 5))
sns.histplot(data=df, x="body_mass_g", hue="species", kde=True, bins=25)
plt.title("Distribuicao da massa corporal por especie")
plt.xlabel("Massa corporal (g)")
```

```
plt.ylabel("Frequencia")
plt.show()
```




Por que este grafico: o histograma e a forma padrao de visualizar a *distribuição* de uma variavel numerica; separando por cor (`hue`) comparo as tres especies na mesma escala.

O que obtive: a distribuicao geral e bimodal. Adelie e Chinstrap se sobrepõem quase totalmente (3.000-4.500 g), enquanto Gentoo forma um grupo claramente mais pesado (4.500-6.000 g). Ou seja, a massa corporal sozinha ja separa Gentoo das outras duas, mas nao distingue Adelie de Chinstrap.

✓ Grafico 2 - Dispersao: comprimento x profundidade do bico

```
plt.figure(figsize=(8, 5))
sns.scatterplot(data=df, x="bill_length_mm", y="bill_depth_mm",
                hue="species", style="species", s=70)
plt.title("Comprimento x profundidade do bico por especie")
plt.xlabel("Comprimento do bico (mm)")
plt.ylabel("Profundidade do bico (mm)")
plt.show()
```




Por que este grafico: o scatterplot mostra a *relacao entre duas variaveis numericas* e revela agrupamentos naturais.

O que obtive: os tres grupos ficam quase perfeitamente separados. Adelie tem bico curto e profundo, Chinstrap bico longo e profundo, Gentoo bico longo e raso. Este par de atributos e o melhor candidato para classificar a especie, pois resolve exatamente a ambiguidade Adelie/Chinstrap que o Grafico 1 deixou em aberto.

Gráfico 3 - Boxplot do comprimento da nadadeira por especie e sexo

```
plt.figure(figsize=(8, 5))
sns.boxplot(data=df, x="species", y="flipper_length_mm", hue="sex")
plt.title("Comprimento da nadadeira por especie e sexo")
plt.xlabel("Especie")
plt.ylabel("Comprimento da nadadeira (mm)")
plt.show()
```




Por que este grafico: o boxplot resume mediana, quartis, amplitude e outliers, sendo ideal para *comparar grupos categoricos*; o `hue="sex"` acrescenta uma segunda dimensao de comparacao.

O que obtive: Gentoo tem nadadeiras bem maiores (mediana 216 mm) que Adelie e Chinstrap (190-196 mm). Em todas as especies os machos sao maiores que as femeas, com deslocamento consistente das medianas - ha **dimorfismo sexual**. As caixas sao compactas e com poucos outliers, indicando dados limpos e baixa variabilidade interna.

✓ Grafico 4 - Mapa de calor das correlacoes

```
num = df.select_dtypes(include="number")

plt.figure(figsize=(7, 5))
sns.heatmap(num.corr(), annot=True, cmap="coolwarm", vmin=-1, vmax=1, fmt=".")
plt.title("Correlacao entre as variaveis numericas")
plt.show()
```




Por que este grafico: o heatmap mostra de uma so vez a *força e o sinal* de todas as correlacoes entre as variaveis numericas, algo dificil de enxergar rapidamente em uma tabela.

O que obtive: correlacao forte e positiva entre `flipper_length_mm` e `body_mass_g` (0,87): pinguins maiores sao mais pesados. `bill_depth_mm` tem correlacao negativa com massa e nadadeira (-0,47 e -0,58), efeito puxado pelos Gentoo (grandes e de bico raso). Como nadadeira e massa carregam quase a mesma informacao, ha redundancia: para um modelo preditivo, uma das duas poderia ser descartada.

✓ Grafico 5 - Contagem de pinguins por ilha e especie

```
plt.figure(figsize=(8, 5))
sns.countplot(data=df, x="island", hue="species")
plt.title("Quantidade de pinguins por ilha e especie")
plt.xlabel("Ilha")
```

```
plt.ylabel("Quantidade")  
plt.show()
```



Por que este grafico: o countplot e a escolha natural para *frequencia de variaveis categoricas*, permitindo ver a composicao de cada ilha.

O que obtive: a distribuicao geografica nao e uniforme. Biscoe abriga apenas Gentoo e Adelie, Dream apenas Chinstrap e Adelie, e Torgersen **exclusivamente** Adelie. A ilha e, portanto, por si so um forte indicador da especie: quem esta em Torgersen e Adelie, e Gentoo e Chinstrap nunca aparecem juntas. Adelie e a unica especie presente nas tres ilhas.